คำอธิบายคอลัมน์ชุดข้อมูล AquaSat

ไฟล์ aquasat_landsat_lake_water_quality.csv | 603,432 แถว | 43 คอลัมน์

ข้อมูลจับคู่ค่าการสะท้อนแสงจากดาวเทียม Landsat 5/7/8 กับค่าคุณภาพน้ำที่วัดจริงในพื้นที่ (Ross et al., 2019)

ศัพท์พื้นฐาน

- **Landsat** ดาวเทียมสำรวจโลกของ NASA/USGS ถ่ายภาพจุดเดิมซ้ำทุก ~16 วัน
- **Reflectance (การสะท้อนแสง)** สัดส่วนแสงอาทิตย์ที่ผิวน้ำสะท้อนกลับถึงดาวเทียม สีของน้ำเปลี่ยนตามสิ่งที่อยู่ในน้ำ เช่น สาหร่ายทำให้น้ำเขียว ตะกอนทำให้น้ำขุ่นน้ำตาล จึงใช้ทำนายคุณภาพน้ำได้
- **Band (แบนด์)** ช่วงความยาวคลื่นแสงที่ดาวเทียมวัดแยกกัน เทียบได้กับ "ช่องสี" ของกล้อง
- **In-situ** ค่าที่คนลงไปเก็บตัวอย่างน้ำและวัดจริงในพื้นที่
- **Matchup** การจับคู่ภาพดาวเทียมกับค่าที่วัดจริง ณ จุดเดียวกันและเวลาใกล้กัน แต่ละแถวในไฟล์คือหนึ่ง matchup

แนวคิดของงาน: ใช้ค่าการสะท้อนแสง (X) ทำนายคุณภาพน้ำ (y)

1. ค่าการสะท้อนแสงจากดาวเทียม -> Feature (X)

คอลัมน์	ความหมาย
blue	แบนด์แสงสีน้ำเงิน (~450–520 nm)
green	แบนด์แสงสีเขียว (~520–600 nm) ไวต่อคลอโรฟิลล์ของสาหร่าย
red	แบนด์แสงสีแดง (~630–690 nm) ไวต่อตะกอนและคลอโรฟิลล์
nir	Near-Infrared อินฟราเรดใกล้ (~770–900 nm) ตามองไม่เห็น น้ำใสดูดกลืนเกือบหมด ถ้าค่าสูงแปลว่าน้ำขุ่นหรือมีสาหร่ายมาก
swir1, swir2	Short-Wave Infrared อินฟราเรดคลื่นสั้น 2 ช่วง น้ำดูดกลืนแทบทั้งหมด มักใช้แยกน้ำออกจากบก
***_sd (เช่น blue_sd)**	Standard deviation ของค่าพิกเซลรอบจุดวัด ถ้าสูงแปลว่าพิกเซลต่างกันมาก (อาจมีบก เมฆ หรือขอบฝั่งปน)
pixelCount	จำนวนพิกเซลน้ำที่นำมาคำนวณค่า ยิ่งมากยิ่งเชื่อถือได้

หมายเหตุ: ค่าในไฟล์ถูกคูณ scale ไว้ ต้องคูณ 0.0001 เพื่อแปลงเป็น reflectance จริง (0–1) เช่น blue = 230 คือ 0.023 ตามมาตรฐาน Landsat Collection 1 Surface Reflectance

2. ค่าคุณภาพน้ำที่วัดจริง -> Target (y)

คอลัมน์	ชื่อเต็ม	ความหมาย	หน่วย
chl_a	Chlorophyll-a	ปริมาณคลอโรฟิลล์ บอกปริมาณสาหร่าย ถ้าสูงมากเสี่ยงสาหร่ายบลูม (eutrophication)	µg/L
doc	Dissolved Organic Carbon	คาร์บอนอินทรีย์ที่ละลายในน้ำ ทำให้น้ำออกสีชา/น้ำตาล	mg/L
secchi	Secchi Disk Depth	ความใส: หย่อนจานขาวดำลงน้ำแล้ววัดความลึกที่เริ่มมองไม่เห็น ยิ่งลึกยิ่งใส	m
tss	Total Suspended Solids	ของแข็งแขวนลอยทั้งหมด (ตะกอน + สาหร่าย) บอกความขุ่น	mg/L
tis	Total Inorganic Solids	เฉพาะตะกอนอนินทรีย์ เช่น ดิน ทราย	mg/L
p_sand	Percent Sand	สัดส่วนทรายในตะกอน	%

ข้อควรระวัง: แต่ละแถวมักวัดไว้แค่บางตัว ที่เหลือเป็น NA ตอนทำโมเดลควรเลือก target ตัวเดียว (นิยม chl_a หรือ secchi) แล้วกรองเฉพาะแถวที่มีค่านั้น

3. ข้อมูลภาพดาวเทียม (metadata)

คอลัมน์	ความหมาย
sat	ดาวเทียมที่ถ่าย: 5 = Landsat 5, 7 = Landsat 7, 8 = Landsat 8 (เซนเซอร์ต่างกันเล็กน้อย ใช้เป็น feature ได้)
path, row	พิกัดกริดภาพ Landsat (ระบบ WRS-2) บอกว่าภาพนี้คือ "แผ่น" ไหนบนโลก
landsat_id	รหัสภาพ เช่น LE07_L1TP_010028_20040823_... อ่านได้ว่า LE07 = Landsat 7, 010028 = path 10 row 28, 20040823 = ถ่ายวันที 23 ส.ค. 2004
clouds	% เมฆปกคลุมทั้งภาพ ถ้าสูงข้อมูลอาจเพี้ยน ควรพิจารณากรองออก
qa, qa_sd	Quality Assessment รหัสคุณภาพพิกเซล (เมฆ เงาเมฆ น้ำ/บก)
time	เวลาที่ดาวเทียมบินผ่าน (UTC)

4. ข้อมูลจุดเก็บตัวอย่าง

คอลัมน์	ความหมาย
SiteID	รหัสจุดเก็บตัวอย่าง
lat, long	ละติจูด / ลองจิจูด
.geo	พิกัดเดียวกันในรูปแบบ GeoJSON (ซ้ำกับ lat/long ตัดทิ้งได้)
type	ประเภทแหล่งน้ำ: Lake (ทะเลสาบ) / Stream (แม่น้ำ) / Estuary (ปากแม่น้ำ)
source	แหล่งข้อมูล: LAGOS (ฐานข้อมูลทะเลสาบสหรัฐฯ ฝั่งตะวันออกเฉียงเหนือ) หรือ WQP (Water Quality Portal ของรัฐบาลสหรัฐฯ)
pwater	% ที่พิกเซลนั้นเป็นน้ำตลอดหลายสิบปี (JRC Global Surface Water) ใกล้ 100 = น้ำถาวร ไม่ใช่ขอบฝั่ง
TZID	Time zone ของจุดนัน เช่น America/New_York

5. วันเวลาและการจับคู่

คอลัมน์	ความหมาย
date	วันที่เก็บตัวอย่างน้ำ (เวลาท้องถิ่น)
date_only	TRUE = บันทึกแค่วันที ไม่มีเวลา จึงสมมติว่าเก็บตอนเทียงตามเวลาท้องถิน
date_utc	วันเวลาเก็บตัวอย่างที่แปลงเป็น UTC แล้ว
date_unity	วันที่ที่ใช้ตอนจับคู่กับภาพดาวเทียม
endtime	เวลาสิ้นสุดการเก็บตัวอย่าง (ส่วนใหญ่เป็น 00:00:00 = ไม่มีข้อมูล)
timediff	ห่างกันกี่ชั่วโมงระหว่างเวลาเก็บตัวอย่างกับเวลาดาวเทียมผ่าน เช่น 0.96 = ห่างไม่ถึง 1 ชม. ส่วน -22.9 = ห่างเกือบ 1 วัน ค่ายิ่งใกล้ 0 ยิ่งน่าเชื่อถือ

6. คอลัมน์ที่ไม่ค่อยมีประโยชน์ (ตัดทิ้งได้)

คอลัมน์	ความหมาย
system:index	เลขลำดับแถวที่ Google Earth Engine สร้างตอน export
id	ป้ายกำกับภายในของ AquaSat (ในแถวตัวอย่างเป็น "New")

สรุปสำหรับทำโมเดล

- **X (feature หลัก):** blue, green, red, nir, swir1, swir2 และอาจเพิ่ม sat, pixelCount, pwater หรือสร้าง band ratio เช่น green/red, NDVI
- **y (target):** เลือกหนึ่งตัวจาก chl_a, secchi, tss, doc
- **ใช้กรองข้อมูล:** clouds, timediff, pwater, type (ถ้าโฟกัสเฉพาะทะเลสาบ ให้เลือก type == "Lake")